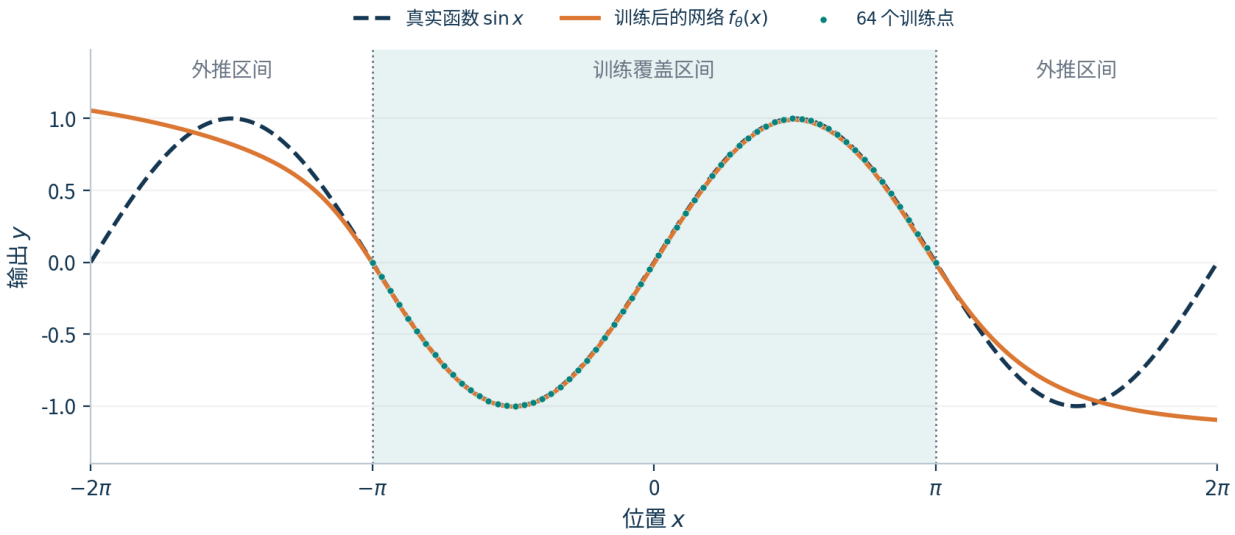
从正弦拟合到噪声预测

用真实实验理解参数、损失、梯度和泛化



先记住这个结果

网络只用 64 个位置训练，却在 511 个未见过的区间内位置上取得了 **0.00006025** 的均方误差。超出训练区间后，误差升至 **0.138786**。我们要理解这两个结果为什么能同时出现。

先看数据与网络参数 2–3 页

用数字理解损失、梯度和训练过程 4–6 页

解释未见位置上的预测 7 页

把预测目标换成噪声 8–10 页

动手练习、自测与复现 11–12 页

面向第一次训练神经网络的读者。 不需要 GPU 或外部数据集。

数据来自本仓库的真实运行；公式中的演示计算会单独说明。

版本日期：2026 年 10 月 13 日

01 / 数据

网络看见了什么?

我们让网络输入一个位置 x，输出一个数 $\hat{y}$，目标是让它接近 $\sin x$。 这是一项监督学习任务：训练时既有问题，也有正确答案。

训练集与测试集承担不同任务

数据	点数	范围与用途
训练集	64	$[-\pi, \pi]$ 等距取点；用于计算梯度并更新参数。
区间内测试集	511	同一区间内的新位置；与训练位置不重合。
区间外测试集	512	$[-2\pi, -\pi)$ 与 $(\pi, 2\pi]$；检验外推。

训练结束后，我们才用测试集给最终模型评分。测试答案没有参与参数更新。 第 6 页的补充训练记录也只用来解释过程，没有据此选模型或提前停止。

直接查看几个没有训练过的位置

x	真实值 $\sin x$	网络预测	绝对误差	位置
-2.5	-0.59847	-0.60011	0.00164	区间内
-0.7	-0.64422	-0.64948	0.00527	区间内
0.4	0.38942	0.38061	0.00881	区间内
1.8	0.97385	0.96346	0.01039	区间内
4.0	-0.75680	-0.66168	0.09512	区间外

表中所有预测来自已保存的模型与指标文件；数字保留 5 位小数。

网络没有在预测时调用正弦函数

我们调用 `sin` 来生成训练答案、计算测试误差、画参考曲线。 网络自身的前向计算只有线性层与 Tanh。训练好以后，新位置也经过同一套运算。

读表练习

在 $x = 0.4$，预测与答案只相差约 0.008813； 在区间外的 $x = 4$，误差约为 0.095。少数例子能帮助建立直觉， 但判断整体表现仍要看完整测试集，不能只挑预测较好的点。

02 / 参数

1,153 个数怎样决定一条曲线?

网络的结构是:

$$1 \xrightarrow{\text{Linear}} 32 \xrightarrow{\tanh} 32 \xrightarrow{\text{Linear}} 32 \xrightarrow{\tanh} 32 \xrightarrow{\text{Linear}} 1.$$

输入在送入网络前除以 π，所以训练时内部输入范围是 $[-1, 1]$。 用矩阵写出它实际计算的函数:

$$\begin{aligned} h_1 &= \tanh(W_1(x/\pi) + b_1)\,, \\ h_2 &= \tanh(W_2 h_1 + b_2), \\ \hat{y} &= W_3 h_2 + b_3. \end{aligned}$$

全部权重 W 和偏置 b 合在一起叫作参数 θ。训练就是不断调整它们， 使函数 $f_\theta(x)$ 的形状逐渐适合数据。

层	权重数	偏置数	小计
输入到隐藏层 1	$1 \times 32 = 32$	32	64
隐藏层 1 到隐藏层 2	$32 \times 32 = 1024$	32	1,056
隐藏层 2 到输出	$32 \times 1 = 32$	1	33
总计	1,088	65	**1,153**

训练改变参数；预测保留参数

新位置 x 是一次查询，不是一个新参数。学习率 0.01、隐藏层宽度 32、 更新次数 2,500 是我们选定的**超参数**，也不等于网络学到的权重和偏置。

为什么需要 Tanh?

如果去掉激活函数，任意多层线性变换合起来仍是 $ax + b$，只能画出直线。 Tanh 提供非线性，让许多简单的变换组合成弯曲的函数。

参数多，不代表自动理解规律

本例参数数目比训练点数还多。仅凭“训练误差小”无法证明网络学到了 唯一正确的规律；第 7 页将用外推结果说明这个限制。

03 / 损失

把“错了多少”变成一个数

对 N 个样本，均方误差 MSE 定义为：

$$L(\theta) = \frac{1}{N}\sum_{i=1}^{N}\left[f_\theta(x_i) - y_i\right]^2, \qquad y_i = \sin x_i.$$

先逐点计算偏差，平方后求平均。平方使正负偏差不会互相抵消，也让较大的误差受到更重惩罚。

用 $x = 0.4$ 的真实预测手算一次

真实值为 0.38941835，预测值为 0.38060507。
$e = \hat{y} - y \approx -0.00881328$，因此 $e^2 \approx 0.00007767$。
这是一**个点的平方误差**。对整个集合的所有点做相同计算并取平均，才是该集合的 MSE。

三个误差，三个不同的问题

评估集合	MSE	RMSE：MSE 的平方根
训练集	0.00006001	0.007747
区间内测试集	0.00006025	0.007762
区间外测试集	0.138786	0.372540

RMSE 与输出 y 的量纲一致，比平方后的数值更便于理解。 本例区间内 RMSE 约为 0.0078，而正弦输出范围是 $[-1, 1]$。 这表示一种整体误差尺度，**不是最大误差，也不是每一点的误差上限**。

损失告诉我们哪里做得好，但不解释为什么

训练集 MSE 从 0.731648降到 0.00006001，约缩小了 12,192倍。 它证明优化过程显著改善了训练点的拟合；区间内泛化好不好， 要由没有参与更新的 511 个位置另行检验。

这里的测试 MSE 只用于最终评分。训练优化器最小化的始终是训练集 MSE。

04 / 梯度

怎样知道每个参数该往哪调?

对一个参数 θ_j，链式法则给出:

$$\frac{\partial L}{\partial \theta_j} = \frac{2}{N}\sum_i \underbrace{(f_\theta(x_i) - y_i)}_{\text{预测偏差}} \underbrace{\frac{\partial f_\theta(x_i)}{\partial \theta_j}}_{\text{参数对预测的影响}} .$$

梯度是损失对参数的导数，不是 $\sin x$ 对 x 的导数。 反向传播高效地计算所有参数的梯度；优化器据此调整参数。

追踪首层的第一个权重：真实运行记录

初始化值 w	0.7645385265
第一次反向传播得到的 $\partial L/\partial w$	0.0069904281
中心差分核对的梯度	0.0069904277
第一次 Adam 更新后的 w	0.7545385361

梯度为正，意味着在当前位置附近，单独把这个权重稍微减小通常有利于降低损失。

普通梯度下降与实际使用的 Adam

普通梯度下降是 $w \leftarrow w - \eta\,\partial L/\partial w$。 若取 $\eta = 0.01$，本次这个权重会减少约 0.00006990。 这只是对照计算；实际使用的 Adam 还利用梯度的历史均值与平方均值， 本次首步变化约为 0.00999999，不能把两种更新公式混为一谈。

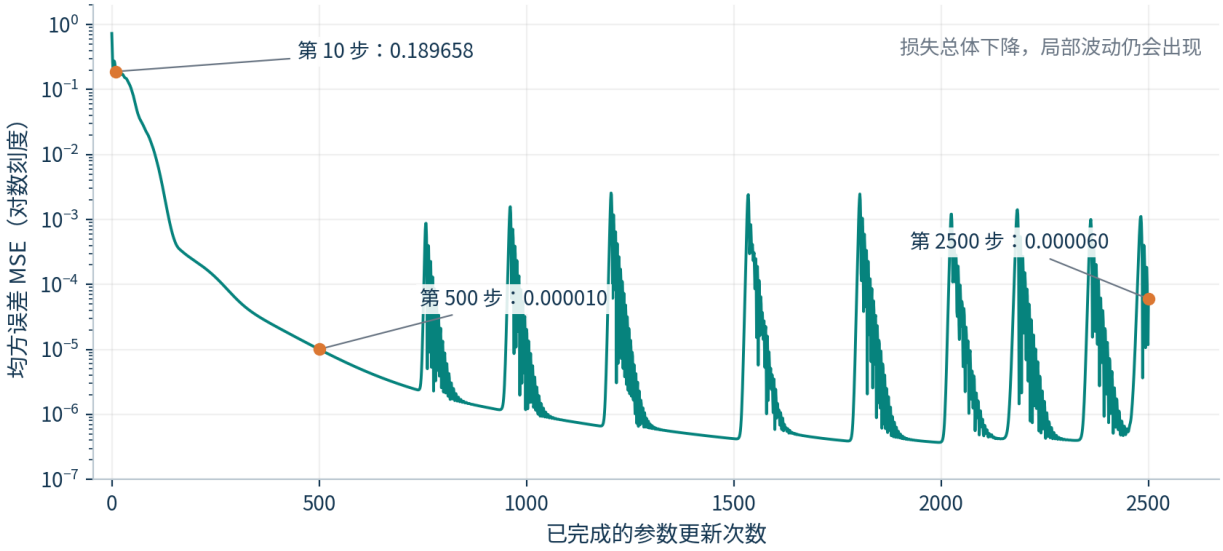
```
y_pred = predict(model, x_train)
loss = loss_fn(y_pred, y_train)
optimizer.zero_grad()
loss.backward()
optimizer.step()
```

这五行依次完成：预测、评分、清除旧梯度、计算新梯度、更新参数。 `backward()` 自己不会改变权重；实际修改发生在 `step()`。

中心差分用 $[L(w+h) - L(w-h)]/(2h)$ 核对导数；为减少舍入误差， 核对时用同一初始化权重的双精度副本，不把它代回实际训练。

05 / 训练过程

损失曲线为什么有尖峰?



补充重放同一种子、同一训练配置；横轴是已经完成的更新次数， 纵轴是该时刻参数对应的训练 MSE，使用对数刻度。

已完成更新次数	训练 MSE	区间内测试 MSE
0	0.731647849	0.743359864
10	0.189658418	0.174011141
100	0.012287968	0.010978906
500	0.000010038	0.000008375
1,500	0.000000422	0.000000388
2,500	0.000060010	0.000060252

从曲线读出三件事

1. 初期误差快速下降，说明梯度提供了有用的调整信息。
2. 后期损失很小，但固定学习率与 Adam 的更新仍可能引起振荡。 最后一步不一定比之前的每一步更好。
3. 尖峰本身不能证明过拟合。判断过拟合通常需要同时分析训练与独立验证表现。

本次没有选择曲线的最低点当结果

我们预先固定运行 2,500 步，然后报告最后一组参数的表现。 表中的测试数据只做补充诊断，没有用于早停或挑选最佳模型。

06 / 泛化

为什么新位置能预测，却不总是准确？

能计算新位置，来自函数结构：所有位置共享同一组参数。

能在新位置算准，则需要合适的数据覆盖、目标规律和训练结果，并由独立测试确认。



误差使用对数坐标。区间外 MSE 约为区间内的 2,303倍， 但两类点来自不同范围，这个比值描述本实验的分布变化，不是普适常数。

本例为什么容易在样本之间预测准确？

训练点均匀覆盖 $[-\pi, \pi]$，区间内的新位置离已知位置很近； $\sin x$ 平滑，Tanh 网络也适合表达平滑曲线。 参数共享使各个位置的输出关联起来。这些条件有助于泛化，但不提供数学保证。

为什么区间外会失真？

网络没有内置“每隔 2π 重复一次”的要求，训练数据也只覆盖一个有限区间。 许多不同的平滑曲线可以穿过相同的训练点，却在区间外有完全不同的走向。

这个实验支持的结论

该模型在这次训练区间内的未见位置上近似得很好。 它没有因此被证明发现了正弦的解析公式，也没有学会可靠的周期外推。

“网络是连续函数”只解释预测为何随输入连续变化，不能独自保证预测正确。 换随机种子、数据范围或模型结构，结果也可能改变。

07 / 换一个目标

从拟合数值，到预测加入的噪声

现在换一下记号：用 u 表示原来的横坐标，令 $x_0 = \sin u$。 u 在 $[-\pi, \pi]$ 上均匀抽样，所以一个干净样本 x_0 是**一个标量**，不是一整条正弦曲线。

每次训练，抽取时间 t 和标准正态噪声 ϵ，构造：

$$\epsilon \sim \mathcal{N}(0,1), \qquad x_t = \sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1-\bar{\alpha}_t}\, \epsilon.$$

$\bar{\alpha}_t$ 是信号系数的平方，描述信号保留程度。它越小，信号越弱、噪声越强。 本例使用余弦日程，t 在 $[0.1, 0.9]$ 内均匀抽样，避开纯噪声端点还原公式的除零与端点退化。

项目	正弦拟合	噪声预测
输入	位置 x	带噪样本 x_t 与时间 t
目标	$\sin x$	本次抽取的标准噪声 ϵ
网络	$1 \to 32 \to 32 \to 1$	$2 \to 32 \to 32 \to 1$
参数量	1,153	1,185
训练	固定 64 点，2,500 次更新	每次新抽 256 点，1,500 次更新
评估	独立的位置	独立的信号、时间与噪声

损失还是 MSE：

$$L_{\text{noise}}(\theta) = \mathbb{E}\left[\left(\epsilon_\theta(x_t, t) - \epsilon\right)^2\right].$$

我们亲手加了噪声，所以训练时知道答案 ϵ。 网络只得到 (x_t, t)，没有得到 x_0、u 或实际噪声答案。

改变目标时，也必须改变输入

如果网络仍然只看到原始坐标 u，却要预测与它独立的随机噪声， 平方损失下最好的预测就是零。带噪观测 x_t 才提供了有关本次噪声的信息。

预测目标是标准化噪声 ϵ；真正加到信号上的扰动为 $\sqrt{1-\bar{\alpha}_t}\epsilon$。权重更新、反向传播与优化器的职责没有改变。

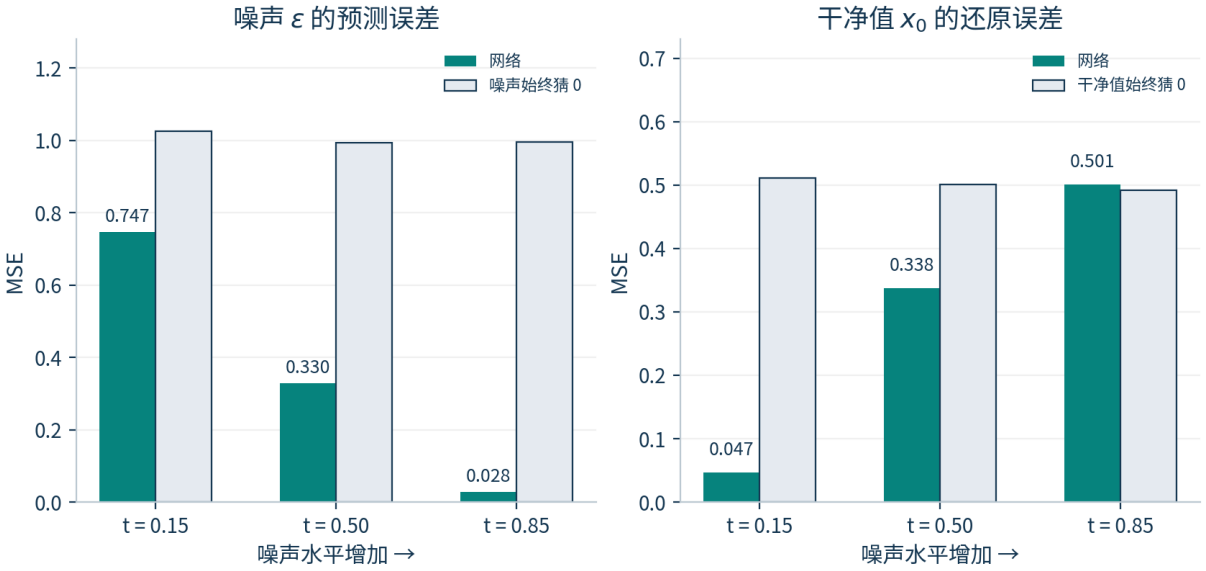
08 / 噪声实验

比“猜零”更好，具体好在哪里？

混合噪声水平的独立测试集有 4,096 个样本。下表的比较使用同一批样本：

评估目标	方法	MSE
标准噪声 ϵ	始终预测为零	1.015650
标准噪声 ϵ	小网络预测	0.356021
干净信号 x_0	直接把 x_t 当答案	0.606127
干净信号 x_0	利用噪声预测还原	0.308780

噪声 MSE 相对零预测基线降低约 64.9%。基线的总体期望为 1， 因为标准正态噪声的方差是 1；有限测试样本的实测值不必恰好等于 1。



每个固定时间另用 4,096 个独立样本。左右两图的目标不同， 不能把“噪声误差小”直接当作“原信号恢复好”。

t	噪声 MSE	信号估计 MSE	信号始终猜零的 MSE
0.15	0.747322	0.047077	0.510760
0.50	0.329664	0.337883	0.500959
0.85	0.028426	0.501321	0.492343

一个容易违反直觉的结果

当 $t = 0.85$ 时，噪声误差只有约 0.028，但信号误差约为 0.501， 本次甚至略高于把信号始终猜零的 0.492。下一页解释原因。

09 / 扩散入口

噪声容易预测，原信号仍可能丢失

利用预测噪声，可以从前向加噪公式中解出干净信号的估计：

$$\hat{x}_0 = \frac{x_t - \sqrt{1-\bar{\alpha}_t}\,\epsilon_\theta(x_t, t)}{\sqrt{\bar{\alpha}_t}}.$$

把真实的 x_0 减去，可得到一个精确的误差关系：

$$\hat{x}_0 - x_0 = \sqrt{\frac{1-\bar{\alpha}_t}{\bar{\alpha}_t}}\,(\epsilon - \hat{\epsilon}).$$

因此，对**固定时间 t 的同一批样本**：

$$\mathrm{MSE}_{x_0} = \frac{1-\bar{\alpha}_t}{\bar{\alpha}_t}\,\mathrm{MSE}_\epsilon.$$

代入高噪声实验的数据

$t = 0.85$ 时，$\bar{\alpha}_t \approx 0.05366$，误差放大系数约为 17.636。
$17.636 \times 0.028426 \approx 0.50132$，正好对应实测的信号 MSE。
高噪声时 x_t 大部分来自噪声，所以噪声较容易估计；但干净信号留下的信息很少。

为什么无法逐个找回这次真实的噪声？

同一个 (x_t, t) 可能由不同的 x_0 与 ϵ 组合产生。 理想的平方损失预测器给出条件均值 $\mathbb{E}[\epsilon \mid x_t, t]$，而非必然找回本次实际噪声。 实际小网络还受容量与优化误差限制，不等同于理想预测器。

它离完整扩散模型还差什么？

我们已经有“加噪造题、以噪声为答案”的训练方式。 完整生成还需与噪声日程匹配的多步反向采样，从随机噪声逐步生成样本：

$$x_T \longrightarrow x_{T-1} \longrightarrow \cdots \longrightarrow x_0.$$

当前脚本只在中间时间范围训练并做一次信号估计，没有实现这条生成链。 不能把“一步还原公式”直接当作完整采样算法。

10 / 动手与自测

把结果变成自己的理解

先运行已有练习，再做两个对照

当前云环境已经装好依赖。从仓库根目录运行：

```
cd /workspace/Ai-for-physics
.venv/bin/python exercises/01_fit_sine.py
.venv/bin/python exercises/02_predict_noise.py

.venv/bin/python exercises/01_fit_sine.py \
  --steps 10 --output-dir outputs/short
.venv/bin/python exercises/01_fit_sine.py \
  --seed 7 --output-dir outputs/seed7
```

默认命令会覆盖 `outputs/` 中的同名结果。 做对照时用新的输出目录保留结果；种子 7 是留给读者的拓展， 本教程的定量结论来自种子 42。

先作答，再看参考解释

1. **1,153 个参数里包括输入位置 x 吗?**

   不包括。参数是权重和偏置；位置是一次前向计算的输入。

2. **训练误差很小，能说网络学会了任意范围的正弦吗?**

   不能。本例区间外误差明显较大，说明好插值不等于好外推。

3. **预测新位置时，为什么不用再次反向传播?**

   预测只需固定参数后的前向计算。反向传播用于计算损失对参数的梯度。

4. **看到训练曲线有尖峰，能立即判断过拟合吗?**

   不能。更新可能引起振荡；需要训练与验证表现等证据区分原因。

5. **$t = 0.85$ 的噪声误差很小，为什么信号仍恢复得差?**

   观测中干净信号信息少，且还原公式会放大噪声预测误差。

完成练习的标准

能说明哪些量在训练中改变；能手算一个点的平方误差； 能区分训练、插值与外推；能解释噪声实验中输入和目标各是什么。

附录 / 数据与复现

每个数字从哪里来?

原始实验与补充记录

文件	内容
`outputs/sine_metrics.json`	原始正弦拟合结果、首步梯度范数、查询点预测。
`outputs/noise_metrics.json`	噪声实验的混合测试与分时间测试结果。
`outputs/sine_model.pt`	原始正弦网络的已训练参数。
`docs/assets/supplement_metrics.json`	重放得到的训练轨迹、阶段误差、单权重与梯度核对。
`docs/assets/`	本教程使用的中文图表与原始指标副本。

实验条件

Python 3.12.14，PyTorch 2.10.0+cpu，NumPy 2.3.5，Matplotlib 3.10.8； CPU 单线程。正弦实验：种子 42、Adam 学习率 0.01、2,500 次完整训练集更新。 噪声实验：模型种子 42、训练数据种子 43、测试数据种子 1042、 Adam 学习率 0.002、每批 256 点、1,500 次更新。

噪声日程的精确定义是

$$\bar{\alpha}_t = \frac{\cos^2\left(\frac{t+0.008}{1.008}\frac{\pi}{2}\right)}{\cos^2\left(\frac{0.008}{1.008}\frac{\pi}{2}\right)}.$$

两个系数平方和为 1；但本例 $x_0 = \sin u$ 的方差约为 $1/2$， 所以 x_t 的方差并不在所有时刻都等于 1。

重新构建这份 PDF

图表由标准绘图库生成，正文与公式用 XeLaTeX 排版。 系统需有 XeLaTeX、Noto CJK 字体与本仓库的 Python 依赖。

```
.venv/bin/python docs/build_figures.py
.venv/bin/python docs/build_pdf.py
```

补充脚本核对默认训练的最终指标与原始结果一致。数字因显示精度做了四舍五入， 计算采用完整精度；原始指标的 SHA-256 校验值记录在 `docs/build_manifest.json`，便于检查来源。

结论的适用范围

这是一组固定配置下的教学实验，不是多随机种子的统计评测。 它验证了本例中的插值能力与噪声预测学习过程，未验证完整扩散采样。 图表与结果应结合各自的训练范围、预测目标和基线一起解读。